LABORATUVAR 7 · BIESSE ROVER A 1632 SMART

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad	Grup	Tarih
Ömer Can Gümüş	Gece - 245541008	06.11.2026

Kavram — Tahmin ≠ emniyet: YZ çıktısı olasılıksaldır; emniyet işlevleri bağımsız, doğrulanmış korumalarla yürür. Rover A 1632 Smart'ta YZ özelliği kamuya açık kaynakta doğrulanmadı; bu yalnızca eğitim senaryosudur.

Senaryo (varsayımsal): Kamera tabanlı kalite YZ'si kusurlu parçaya OK verebilir; Biesse özelliği doğrulanmadı.

Kamera → YZ Modeli → OK / RED → İnsan onayı → İşleme

Görev — üç başarısızlıkta güvenli davranış

Yanlış sınıflandırma: Hatalı parçaya OK verildi. Serbest bırakma kararı nasıl korunur?

Parçayı HOLD et; ikinci kontrol/insan onayı olmadan serbest bırakma, kararı kaydet.

AI yalnızca kalite kararını destekler; kapı kilidi/E-stop veya güvenli duruşu yönetmez.

Girdi manipüle edildi: Bozuk/sahte kamera verisinde hangi kontrol ve fallback çalışır?

Bütünlük, zaman ve görüntü kalitesi kontrolü başarısızsa sonucu reddet; olay kaydı aç.

Parçayı HOLD et ve yetkili manuel incelemeye yönlendir; girdi hatasını kaydet.

Güven skoru düştü veya model yanıt vermedi: süreç nasıl fail-safe olur?

Eşik temsilî test ve riskle belirlenir; altındaysa HOLD + yetkili insan incelemesi.

AI'sız fallback ancak önceden doğrulanmışsa; emniyet işlevleri AI'dan bağımsız kalır.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	HOLD; ikinci kontrol/insan onayı. AI emniyet zincirine girmez.
Girdi manipüle edildi	Girdiyi reddet; HOLD ve manuel inceleme; olayı kaydet.
Güven skoru düştü	Eşik altı HOLD; insan onayı veya doğrulanmış AI'sız fallback.

Bu föyün çıktısı AI Fail-Safe Decision → Evidence Pack EP 03 + EP 15 başlığına oturur.

Kaynak: NIST AI RMF 1.0, geçerlilik/güvenilirlik, güvenlik, izleme ve güvenli başarısızlık.